Course: Big Data

Lab 05

PySpark - DataFrame

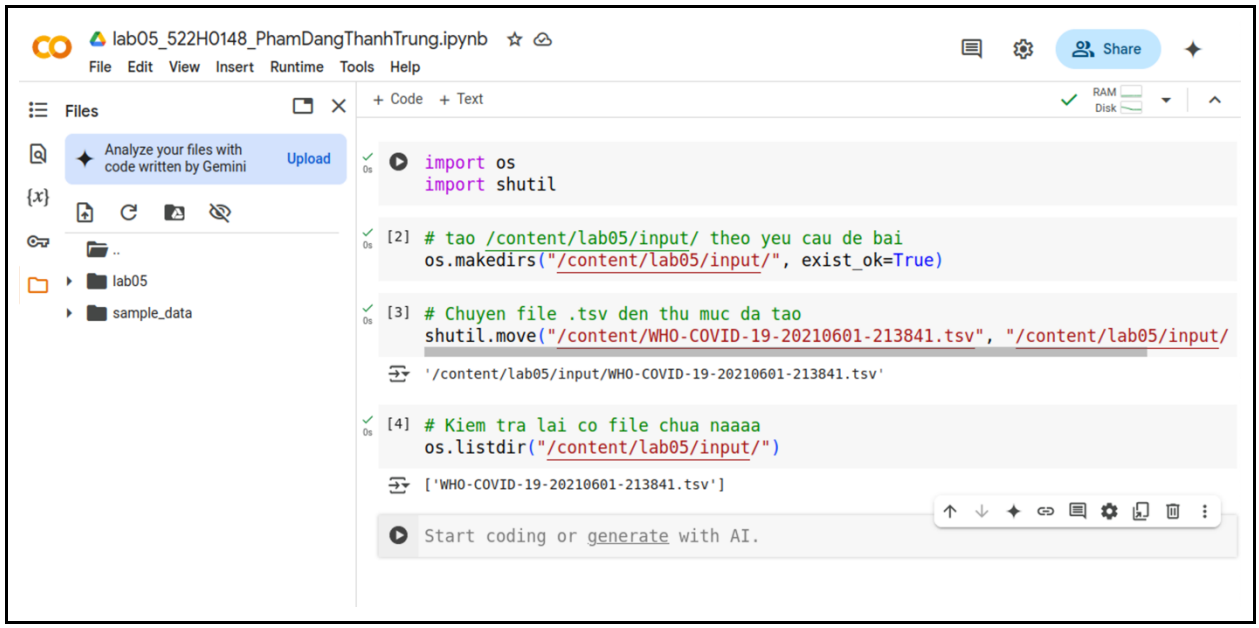
522H0148 - Phạm Đặng Thanh Trung

Question 1:

Given a tsv file WHO-COVID-19-20210601-213841.tsv which is corresponding to the WHO Coronavirus (COVID-19) Dashboard.

Students are required to create a folder, named **lab05**, in **/content** directory of Google Colab and then copy the tsv to **/content/lab05/input/**

Take a screenshot to show your work.



Question 2:

Write a PySpark program, located in **ASEANCaseCount.py**, using DataFrames to

- to count the number of cumulative total cases among ASEAN countries (*South-East Asia Region in the given data table*)

- to find the country with the maximum number of cumulative total cases among ASEAN countries.
- to find the top 3 countries with the lowest number of cumulative cases among ASEAN countries.

- Insert your source code into the table below.

```
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, sum, max, asc, desc, regexp_replace

#Khởi tạo Spark Session
spark=SparkSession.builder.appName("ASEAN_COVID_Cases").getOrCreate()

#Đọc dữ liệu từ file TSV
file_path="/content/lab05/input/WHO-COVID-19-20210601-213841.tsv"
df=spark.read.option("header", True).option("sep", "\t").csv(file_path)

#Danh sách các nước ASEAN
ASEAN_COUNTRIES=[
    "Brunei Darussalam", "Cambodia", "Indonesia", "Lao People's Democratic Republic",
    "Malaysia", "Myanmar", "Philippines", "Singapore", "Thailand", "Viet Nam"
]

#Chuẩn hóa tên cột để tránh lỗi khoảng trắng
df=df.withColumnRenamed("Cases - cumulative total", "Cumulative_cases") \
      .withColumnRenamed("Name", "Country")

#Lọc dữ liệu ASEAN
df_asean=df.filter(col("Country").isin(ASEAN_COUNTRIES))

#Xử lý dữ liệu đúng định dạng số
df_asean=df_asean.withColumn("Cumulative_cases",
    regexp_replace(col("Cumulative_cases"), ",", "").cast("float")  #Xóa dấu ',' trước rồi chuyển
sang float
).na.fill({"Cumulative_cases": 0})

#Tính tổng số ca nhiễm ở ASEAN
total_cases=df_asean.select(sum("Cumulative_cases")).collect()[0][0]

#Tìm quốc gia có số ca nhiễm cao nhất
max_case_country=df_asean.orderBy(desc("Cumulative_cases")).limit(1).collect()[0]
max_country_name=max_case_country["Country"]
max_country_cases=int(max_case_country["Cumulative_cases"])  #Chuyển về số nguyên
cho dễ đọc

#Tìm 3 quốc gia có số ca nhiễm thấp nhất
min_countries=df_asean.orderBy(asc("Cumulative_cases")).limit(3)

#Hiển thị kết quả
```

```
print(f"Tổng số ca nhiễm ở ASEAN: {int(total_cases):,}")  #In số có dấu phẩy phân cách
print(f"Quốc gia có số ca nhiễm cao nhất: {max_country_name} ({max_country_cases:,} ca)")
print("Ba quốc gia có số ca nhiễm thấp nhất:")
min_countries.select("Country", "Cumulative_cases").show()

#Dừng Spark session
spark.stop()
```

- Take a screenshot of the terminal to visualize the program result.

```
Tổng số ca nhiễm ở ASEAN: 4,031,744
Quốc gia có số ca nhiễm cao nhất: Indonesia (1,821,703 ca)
Ba quốc gia có số ca nhiễm thấp nhất:
+--------------------+----------------+
|             Country|Cumulative_cases|
+--------------------+----------------+
|   Brunei Darussalam|           243.0|
|Lao People's Demo...|          1912.0|
|            Viet Nam|          7432.0|
+--------------------+----------------+
```

Submission Notice

- Export your answer file as pdf
- Rename the pdf following the format:

  lab05_<student number>_<full name>.pdf

  E.g. lab05_123456_NguyenThanhAn.pdf

  If you have not been assigned a student number yet, then use 123456 instead.
- Careless mistakes in filename, format, question order, etc. are not accepted (0 pts).